LinearRegression_Part2

January 2, 2022

0.0.1 Dataset para el conjunto de entrenamiento y testing

```
[84]: #---- Incluímos las librerías a emplear ----
      import numpy as np
      import pandas as pd
      import matplotlib.pyplot as plt
[85]: #---- Cargamos y visualizamos el dataframe -----
      data = pd.read_csv(r"D:
      →\Curso-Jupyter-Notebook\MachineLearning\datasets\Advertising.csv")
      data.head(20)
[85]:
                Radio Newspaper
             TV
                                   Sales
      0
          230.1
                  37.8
                             69.2
                                    22.1
      1
          44.5
                  39.3
                             45.1
                                    10.4
      2
           17.2
                  45.9
                             69.3
                                     9.3
      3
          151.5
                  41.3
                             58.5
                                    18.5
          180.8
      4
                  10.8
                             58.4
                                    12.9
      5
            8.7
                  48.9
                             75.0
                                    7.2
          57.5
      6
                  32.8
                             23.5
                                    11.8
      7
         120.2
                  19.6
                             11.6
                                   13.2
      8
            8.6
                   2.1
                             1.0
                                    4.8
                             21.2
      9
          199.8
                   2.6
                                    10.6
      10
          66.1
                   5.8
                             24.2
                                    8.6
      11 214.7
                  24.0
                              4.0
                                    17.4
      12
          23.8
                  35.1
                             65.9
                                    9.2
      13
           97.5
                  7.6
                              7.2
                                     9.7
      14 204.1
                  32.9
                             46.0
                                    19.0
      15 195.4
                  47.7
                             52.9
                                    22.4
          67.8
      16
                  36.6
                            114.0
                                    12.5
      17
         281.4
                  39.6
                             55.8
                                    24.4
           69.2
                  20.5
                             18.3
                                    11.3
      18
      19 147.3
                  23.9
                             19.1
                                    14.6
[86]: # Distribución uniforme
      a = np.random.randn(len(data))
      plt.hist(a) # Graficamos un histograma
```

50 - 40 - 30 - 20 - 10 - 0

```
[87]: # División del dataset
check = (a<0.7) # 70% de elementos
training = data[check] # 70%
testing = data[~check] # 30%

# Tamaño de nuestros datasets de entrenamiento y testing
len(training), len(testing)</pre>
```

-1

1

[87]: (152, 48)

```
[88]: # Agregamos el modelo de regresión lineal
import statsmodels.formula.api as smf
# Creamos nuestro modelo de regresión lineal
lm = smf.ols(formula = "Sales~TV+Radio", data = training).fit()
```

[89]: lm.summary() # Inspeccionamos los resultados

[89]: <class 'statsmodels.iolib.summary.Summary'>

OLS Regression Results

Dep. Variable:	Sales	R-squared:	0.890
Model:	OLS	Adj. R-squared:	0.889
Method:	Least Squares	F-statistic:	603.9
Date:	Sun, 02 Jan 2022	Prob (F-statistic):	3.37e-72
Time:	03:05:16	Log-Likelihood:	-297.19
No. Observations:	152	AIC:	600.4
Df Residuals:	149	BIC:	609.5

Df Model: 2 Covariance Type: nonrobust

	coef	std err	t	P> t	[0.025	0.975]
Intercept TV Radio	3.1971 0.0449 0.1821	0.339 0.002 0.009	9.422 27.655 19.542	0.000	2.527 0.042 0.164	3.868 0.048 0.201
Omnibus: Prob(Omnibus) Skew: Kurtosis:	:	0 -1	.000 Jar .497 Pro	bin-Watson: que-Bera (JE b(JB): d. No.	3):	2.101 157.648 5.85e-35 415.

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

11 11 11

[90]: # Validamos nuestro modelo con el conjunto de testing pred = lm.predict(testing) pred

[90]: 12 10.656921 18 10.034436 19 14.156818 29 9.277707 33 18.752923 39 20.289839 40 16.341434 44 9.003334 54 20.225471 58 21.685522 60 5.961048 62 16.753707 68 18.853885 69 20.916587 73 10.039384

```
17.249223
      77
             13.792439
      78
              8.884579
      81
             14.700002
      83
             14.369358
      84
             20.604660
      85
             15.214025
      86
             11.627726
      93
             21.098481
      103
             14.757753
      114
             15.227807
      115
             12.939777
      120
             14.415827
      123
             15.019975
      126
             10.631283
      128
             22.002376
      131
             15.620781
      132
              8.527429
      138
              9.842664
      139
             19.485709
      141
             18.332440
      153
             18.110788
      154
             15.463523
      155
              5.493528
      160
             14.230889
      164
             11.131204
             14.381976
      171
      174
             13.792041
      175
             24.522964
      177
             12.251918
      181
             13.981340
      191
              8.550490
      195
              5.584364
      dtype: float64
[91]: # Suma de los cuadrados de la regresión
      SSD = sum((testing["Sales"] - pred)**2)
      SSD
[91]: 115.52146376954607
[92]: # Error estándar de los residuo
      RSE = np.sqrt(SSD/(len(testing)-2-1))
      RSE # Obtenemos la desviación promedio de los puntos estimados
[92]: 1.6022308320973124
```

74

```
[93]: # Promedio de las ventas
      sales_mean = np.mean(testing["Sales"])
      sales_mean
[93]: 14.445833333333333
[94]: # Error obtenido en el modelo
      error = RSE/sales_mean
      error
[94]: 0.11091300827901787
      0.0.2 Scikit-learn para regresión lineal
[96]: #---- Incluímos las librerías a emplear ----
      import numpy as np
      import pandas as pd
      from sklearn.feature selection import RFE
      from sklearn.svm import SVR
[97]: #---- Cargamos y visualizamos el dataframe -----
      data = pd.read_csv(r"D:
       → \Curso-Jupyter-Notebook \MachineLearning \datasets \Advertising.csv")
      data.head()
[97]:
            TV Radio Newspaper Sales
      0 230.1 37.8
                            69.2
                                   22.1
        44.5
                39.3
                            45.1
                                 10.4
      1
      2 17.2 45.9
                            69.3 9.3
                            58.5 18.5
      3 151.5 41.3
      4 180.8
                            58.4 12.9
                 10.8
[98]: # Extraemos las columnas para nuestra variable predictiva
      feature_cols = ["TV", "Radio", "Newspaper"]
[99]: # Variables de nuestro modelo
      X = data[feature cols]
      Y = data["Sales"]
[100]: estimator = SVR(kernel = "linear") # Modelo de ML a emplear
      # Implementamos los estimadores para el modelo
      selector = RFE(estimator, n_features_to_select = 2, step = 1)
      selector = selector.fit(X, Y) # Creamos el modelo
[101]: # Nuestro modelo aceptó TV y Radio, pero rechazó Newspaper
      selector.support_
```

```
[101]: array([ True, True, False])
[102]: # Importamos directamente el modelo de Regresión lineal
       from sklearn.linear_model import LinearRegression
[103]: # Tomamos nuestras variables predictores
       X_pred = X[["TV", "Radio"]]
[104]: # Creamos el modelo de regresión lineal
       lm = LinearRegression()
       lm.fit(X_pred, Y)
[104]: LinearRegression()
[105]: lm.intercept_
[105]: 2.9210999124051362
[106]: lm.coef
[106]: array([0.04575482, 0.18799423])
[107]: # Eficiencia del modelo
       lm.score(X_pred, Y)
[107]: 0.8971942610828957
      0.0.3 Relaciones no lineales
[108]: #---- Incluímos las librerías a emplear ----
       import pandas as pd
       import numpy as np
       import matplotlib.pyplot as plt
[109]: #---- Cargamos y visualizamos el dataframe -----
       data = pd.read_csv(r"D:
       → \Curso-Jupyter-Notebook \MachineLearning \datasets \auto-mpg.csv")
       data.head()
[109]:
          mpg cylinders displacement horsepower weight acceleration \setminus
       0 18.0
                                  307.0
                                              130.0
                                                       3504
                                                                      12.0
                        8
       1 15.0
                                  350.0
                                              165.0
                                                       3693
                                                                      11.5
                        8
       2 18.0
                                  318.0
                                                       3436
                                                                     11.0
                        8
                                              150.0
       3 16.0
                        8
                                  304.0
                                              150.0
                                                       3433
                                                                      12.0
       4 17.0
                        8
                                  302.0
                                              140.0
                                                       3449
                                                                      10.5
         model year origin
                                               car name
       0
                  70
                           1 chevrolet chevelle malibu
```

```
2
                  70
                            1
                                      plymouth satellite
       3
                  70
                                            amc rebel sst
                            1
       4
                  70
                            1
                                              ford torino
[110]: # Tamaño del dataframe
       data.shape
[110]: (406, 9)
[111]: # Graficamos Horsepower vs MPG
       %matplotlib inline
```

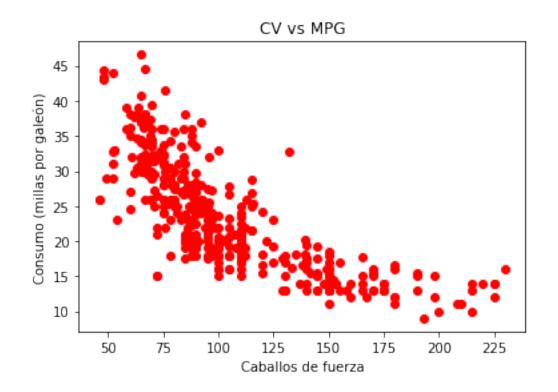
buick skylark 320

[111]: Text(0.5, 1.0, 'CV vs MPG')

70

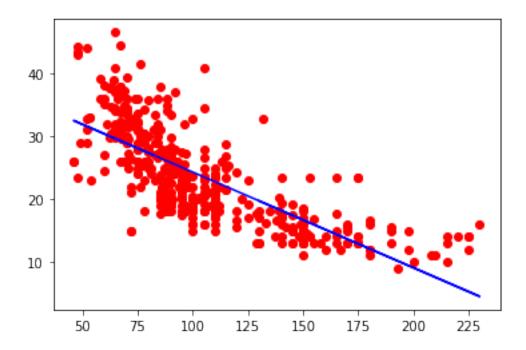
1

1



Modelo de regresión lineal MPG = a + b*Horsepower

```
[112]: # fillna: reemplaza los NAs con el promedio del array
       X = data["horsepower"].fillna(data["horsepower"].mean()).to_numpy()
       Y = data["mpg"].fillna(data["mpg"].mean())
       # Necesitamos mínimo 2 dimensiones para trabajar con LinearRegression
       X_data = X[:, np.newaxis]
[113]: # Creamos el modelo de regresión lineal
       lm = LinearRegression()
       lm.fit(X_data, Y)
[113]: LinearRegression()
[114]: # Verificamos el tipo de dato creado
       type(X)
[114]: numpy.ndarray
[115]: # Verificamos el tipo de dato creado
       type(X_data)
[115]: numpy.ndarray
[116]: # Graficamos los datos y la recta de regresión lineal
       %matplotlib inline
       plt.plot(X, Y, "ro")
       plt.plot(X, lm.predict(X_data), color = "blue")
```



```
[117]: # Eficiencia de nuestro modelo
       lm.score(X_data, Y)
[117]: 0.5746533406450252
[118]: # Principales características del modelo
       SSD = np.sum((Y - lm.predict(X_data))**2)
       RSE = np.sqrt(SSD/(len(X_data) - 1))
       y_mean = np.mean(Y)
       error = RSE/y_mean
       SSD, RSE, y_mean, error
[118]: (10315.751960060918,
        5.046879480825511,
        23.514572864321607,
        0.21462773361633472)
      Modelo de regresión cuadrático MPG = a + b * Horsepower^2
[119]: # Elevamos al cuadrado a nuestra variable predictora
       X_{data} = X**2
       X_data = np.asarray(X_data)
       X_data = X_data[:, np.newaxis]
```

```
[120]: # Creamos el modelo de "Regresión lineal"
       lm = LinearRegression()
       lm.fit(X_data, Y)
[120]: LinearRegression()
[121]: # Eficiencia del modelo
       lm.score(X_data, Y)
[121]: 0.4849887034823205
[122]: # Principales características del modelo
       SSD = np.sum((Y - lm.predict(X_data))**2)
       RSE = np.sqrt(SSD/(len(X_data) - 1))
       y mean = np.mean(Y)
       error = RSE/y_mean
       SSD, RSE, y_mean, error
[122]: (12490.350340501926,
       5.553410772769817,
       23.514572864321607,
       0.23616889852998113)
      Modelo de regresión lineal y cuadrático MPG = a + b * Horsepower + c * Horsepower^2
[74]: #---- Incluímos las librerías a emplear ----
       from sklearn.preprocessing import PolynomialFeatures
       from sklearn import linear model
[75]: # Declaramos un polinomio de grado 2
       poly = PolynomialFeatures(degree = 2)
[76]: # Transformación lineal a partir de los datos originales (X)
       X_data = poly.fit_transform(X[:, np.newaxis])
[77]: # Creamos nuestro modelo
       lm = linear_model.LinearRegression()
       lm.fit(X_data, Y)
[77]: LinearRegression()
[78]: # Eficiencia del modelo
       lm.score(X_data, Y)
[78]: 0.6439066584257469
[79]: lm.intercept_
```